



PROGRAMA DA DISCIPLINA INTRODUÇÃO AO APRENDIZADO DE MÁQUINA

INFORMAÇÕES GERAIS

Créditos: 4	Carga Horária: 60h	Tipo: Optativa
Professor: Alexandre Tadeu Rossini da Silva		Semestre: 2026/1

1 EMENTA

Métodos de regressão. Regularização. Redes Neurais. Support Vector Machines. Aprendizado não supervisionado. Redução de dimensionalidade. Detecção de Anomalias. Sistemas de Recomendação.

2 OBJETIVOS

1.1 Objetivo Geral

Compreender os fundamentos do Aprendizado de Máquina e aplicar técnicas básicas de preparação de dados, modelagem, avaliação e interpretação de modelos utilizando bibliotecas computacionais, desenvolvendo pensamento crítico sobre o uso de dados e algoritmos na resolução de problemas.

1.2 Objetivos Específicos

Ao final da disciplina, o estudante deverá ser capaz de:

- Compreender os conceitos fundamentais de Inteligência Artificial e Aprendizado de Máquina, diferenciando seus principais tipos e aplicações.
- Realizar análise exploratória e preparação de dados, incluindo limpeza, escalonamento e tratamento de inconsistências.
- Implementar e avaliar modelos de classificação e regressão utilizando técnicas básicas de divisão treino/teste e métricas apropriadas.
- Aplicar métodos simples de refinamento de modelos, como tratamento de outliers e seleção de variáveis.
- Compreender e aplicar técnicas introdutórias de aprendizado não supervisionado.

3 CONTEÚDO PROGRAMÁTICO

- Fundamentos de Inteligência Artificial e Aprendizado de Máquina.
- Estrutura e exploração de datasets.
- Limpeza e preparação de dados.
- Classificação: divisão treino/teste e métricas de avaliação.
- Escalonamento, balanceamento e refinamento de modelos.
- Regressão e métricas associadas.
- Aprendizado não supervisionado: clustering (K-means e K-modes).

4 METODOLOGIA

4.1 Ensino

A aula está construída no Ambiente Virtual de Aprendizagem institucional – AVA UFT, contendo:

- Conteúdo base - apostila de referência;
- Conteúdo complementar – materiais que ajudam a trazer melhor entendimento sobre o conteúdo e pode ser utilizado como material de consulta em outros momentos;
- Atividades assíncronas – em cada aula haverá atividades interativas e colaborativas a serem realizadas por meio de fórum de discussão e web atividades com o objetivo de internalizar e mobilizar os conceitos estudados.
- Fórum interativo para discussão sobre a importância do pensamento computacional na formação do licenciado em computação;
- Visitas, previamente agendadas, aos polos.

4.2 Avaliação

A avaliação ocorrerá de maneira formativa e processual, ou seja, será contínua e combinará propostas de atividades para mensurar de forma mais assertiva diferentes aspectos do aprendizado a partir de um diagnóstico da aprendizagem das competências instauradas. Haverá uma proposta de atividade para cada aula e o total delas comporá o diagnóstico de aprendizagem dos alunos com uma média final (Mf). Todas as propostas de atividades terão o mesmo peso e a Mf será obtida por meio da média aritmética do desempenho do estudante. Será aprovado o estudante que obtiver Mf maior ou igual a 7,0; fará exame final caso Mf esteja entre 4,0 e 6,9; e Mf abaixo de 4,0 implica em reprovação.

5 CRONOGRAMA DE AULAS

Semana	Tema/Atividade
1	Máquinas que Aprendem: Fundamentos do Aprendizado de Máquina – Apresentar os conceitos fundamentais de Aprendizado de Máquina, diferenciando IA e Aprendizado de Máquina, compreendendo os principais tipos de aprendizado e o pipeline geral de um projeto de Aprendizado de Máquina.
2	Explorando Dados na Prática: Datasets com Scikit-Learn – Compreender a estrutura de um dataset, diferenciando variáveis e rótulos, explorando bases disponíveis no Scikit-Learn e manipulando dados iniciais com Python.
3	Conhecendo os Dados: Análise Exploratória e Limpeza – Realizar Análise Exploratória de Dados (EDA), identificar padrões e inconsistências, tratar valores ausentes e compreender a importância da qualidade dos dados para o desempenho do modelo.
4	Treinando o Modelo: Classificação e Divisão Treino/Teste – Implementar um modelo de classificação, realizar a divisão entre conjuntos de treino e teste e compreender o conceito de generalização e overfitting.
5	Medindo Desempenho: Métricas e Avaliação de Classificadores – Aplicar métricas de avaliação como acurácia, precisão, recall e F1-score, interpretar matriz de confusão e analisar o desempenho de modelos de classificação.
6	Preparando os Dados para o Modelo: Escalonamento e Balanceamento – Aplicar técnicas de normalização e padronização de dados, compreender o impacto do escalonamento no modelo e discutir estratégias para lidar com dados desbalanceados.
7	Refinando o Modelo: Outliers e Seleção de Variáveis – Identificar e tratar outliers, analisar correlação entre variáveis e aplicar métodos simples de seleção de atributos para melhorar o desempenho e interpretabilidade do modelo.
8	Previsões Numéricas: Introdução à Regressão – Implementar modelos de regressão, compreender a diferença entre problemas de classificação e regressão e avaliar modelos utilizando métricas como MAE e MSE.
9	Descobrendo Padrões Ocultos: Clustering com K-means e K-modes – Compreender o conceito de aprendizado não supervisionado, aplicar algoritmos de agrupamento e interpretar os padrões identificados nos dados.
10	Exame final

6 BIBLIOGRAFIA

6.1 Básica

1. RUSSELL, Stuart J. Inteligência artificial. Rio de Janeiro: Elsevier, 2004.
2. NASCIMENTO JUNIOR, Cairo Lucio. Inteligência artificial: em controle e automação. São Paulo: FAPESP, 2000.
3. CARVALHO, André Carlos Ponce de Leon Ferreira. et al. Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina. 1ª edição. Rio de Janeiro: LTC, 2011.

6.2 Complementar

1. ALPAYDIN, E. Introduction to Machine Learning. MIT Press, 2004.
2. Machine learning. Boston, Mass: McGraw-Hill, c1997.
3. FLACH, P. Machine Learning: The Art and Science of Algorithms that Make Sense of Data. Cambridge University Press, 2012.

Prof. Dr. Alexandre Tadeu Rossini da Silva
Matrícula: 2535210